

INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE OCCIDENTE

DEPARTAMENTO DE MATEMÁTICAS Y FÍSICA
MAESTRÍA EN CIENCIA DE DATOS



SISTEMA DE SOPORTE A LA TOMA DE DECISIONES EN DESARROLLOS INMOBILIARIOS

Presenta:

MARIAN MICHELLE ROMO MARTÍNEZ

Asesor:

DR. EDUARDO ULISES MOYA SÁNCHEZ

San Pedro Tlaquepaque, Jalisco

Agradecimientos

Escribe aquí tus agradecimientos...

Resumen

El sector inmobiliario dentro de México es un pilar fundamental en la economía, el cual se compone principalmente de actividades como la construcción y los mismos servicios inmobiliarios, los cuales impulsan diversas actividades dentro del país por el insumo nacional.

No obstante, los altos niveles de incertidumbre en la fijación de precios y la toma de decisiones, han quedado cortos ante la volatilidad del mismo, debido a su dependencia de criterios subjetivos o modelos simplificados. Por a esta problemática, el presente trabajo propone el desarrollo de un sistema de soporte para la toma de decisiones (DSS) basado en técnicas de ciencia de datos. Dicho sistema se estructura en tres fases: segmentación del mercado mediante algoritmos de clustering, predicción de precios a través de modelos estadísticos y optimización de decisiones para maximizar la rentabilidad bajo restricciones financieras.

Abstract

The real estate sector in Mexico is a fundamental pillar of the economy, comprised mainly of activities such as construction and real estate services, which drive various economic activities within the country due to their reliance on domestic resources.

However, high levels of uncertainty in pricing and decision-making have proven inadequate to address market volatility, stemming from a dependence on subjective criteria or simplified models. Therefore, this paper proposes the development of a decision support system (DSS) based on data science techniques. This system is structured in three phases: market segmentation using clustering algorithms, price prediction through statistical models, and decision optimization to maximize profitability under financial constraints.

Índice

Agradecimientos	1
Resumen	2
Abstract	2
Introducción	5
Contexto	5
Justificación	6
Problema	7
Objetivos	7
Marco teórico	9
Estado del Arte	9
Metodología	10
Recopilación de Datos	10
Análisis de la Información	11
Ingeniería de Características	12
Segmentación	12
Modelo Predictivo	13
Modelo Optimización Convexa	13
Resultados	14
Conclusión	14

Trabajo Futuro 14

Índice de figuras

Introducción

El sector inmobiliario de México ha mostrado ser uno de los motores más importantes en la economía del país. Según el INEGI [1] el sector vivienda alcanzó un valor de 5.4 % del Producto Interno Bruto (PIB) del país, lo que equivale a 1.69 billones de pesos (1,693,949 millones de pesos) en los últimos años. El valor total de este sector se concentra casi por completo (el 95 %) en dos actividades principales: la construcción que representa un 68.7 % del PIB dentro del sector vivienda y los servicios inmobiliarios que representan un 26.7 %. Además, este sector genera un gran impacto en la cadena de valor local al priorizar insumos nacionales; un ejemplo de esto es que los servicios inmobiliarios representan el 88 % de los insumos nacionales según el INEGI.

El sector inmobiliario suele ser de los más expuestos a las políticas monetarias, flujos privados, colocación de fondos, mercado de valores, inversión, entre otras cosas. Es por eso que resulta ser clave y debido a sus complejas relaciones con otras industrias, la diversidad de las propiedades y los factores post-pandemia, el sector ha enfrentado varios desafíos. Debido a todo lo mencionado anteriormente, fijar precios y diseñar estrategias en el mercado se ha vuelto un proceso complejo lleno de incertidumbre.

Las metodologías tradicionales de valuación y toma de decisiones suelen ser insuficientes debido a la dependencia a criterios subjetivos o modelos lineales. Para abordar esta complejidad, el presente proyecto propone un sistema de soporte para tomar decisiones con tres fases:

1. Segmentación: Implementación de algoritmos de clustering para encontrar patrones de comportamiento ocultos en el mercado.
2. Predicción: Desarrollo de modelos predictivos (machine learning) para estimar un intervalo del precio del inmueble.
3. Optimización: Aplicación de técnicas matemáticas para maximizar la rentabilidad de los proyectos, respetando los límites financieros de cada caso.

Contexto

Actualmente el sector inmobiliario en México enfrenta un desequilibrio importante entre la demanda y la oferta de vivienda. Según la Secretaría de Desarrollo Agrario, Territorial y Urbano (SEDATU) y la Comisión Nacional de Vivienda (CONAVI), basados en encuestas del INEGI (ENIGH), el país ha logrado reducir viviendas en condiciones precarias o inadecuadas de 9.24 millones en 2018 a 8.38 millones en 2024 [2]. Sin embargo, se proyecta para el año 2030 una demanda adicional de 6.6 millones de viviendas nuevas [3]. Este aumento en la demanda no se debe únicamente al crecimiento de la población, sino a un cambio en la forma de vida de las familias mexicanas. Por ejemplo, en 1995 el promedio de personas por casa era de

4.77 mientras que en 2025 la cifra bajo a 3.64 [3], lo que implica que se necesitan más viviendas incluso si la población creciera a un ritmo más lento.

A este escenario se le suman tres elementos que estan transformando el panomara inmobiliario del país:

- El crédito hipotecario, aunque conseguir hipotecas se volvió más caro del 2022 en adelante, durante el primer trimestre del 2025 la tasa se ubico en 11.65 % y como señal positiva Banxico bajó su tasa de referencia a 7.75 % en agosto de 2025, su punto mas bajo en 3 años, lo que abre la puerta a que los créditos hipotecarios se vuelvan más accesibles [4].
- El nearshoring especialmente en el norte del país, ha reconfigurado la inversión industrial. Al cierre del primer trimestre de 2026, el inventario industrial de Monterrey alcanzó los 17.9 millones de metros cuadrados en espacios industriales impulsado por más de 3,600 millones de dólares en inversión extranjera directa captados por Nuevo León en 2025 [5]. Para este año 2026, la Asociación Mexicana de Parques Industriales Privados (AMPIP) estima una inversión de 5,830 millones de dólares en todo el país [6].
- Para solucionar el problema de los avalúos que dependendel criterio personal y subjetivo de cada perito, otros países de la región ya usan Inteligencia Artificial (modelos de machine learning). Por ejemplo en Colombia, la Universidad de los Andes realizó un estudio donde analizó a más de 3,700 proyectos con ML para calcular el valor real de los inmuebles de forma masiva y objetiva [7]. En nuestro país todavía no existe un sistema científico, lo que representa una gran oportunidad para desarrollar herramientas tecnológicas que permitan valorar propiedades basándose puramente en datos duros, facilitando decisiones comerciales más inteligentes.

Justificación

La necesidad de un sistema tecnológico basado en datos se justifica por problemas críticos que el mercado mexicano enfrenta hoy en día:

En primer lugar, los métodos tradicionales de valuación presentan limitaciones críticas. El enfoque comparativo de mercado depende en gran medida de la experiencia y el criterio personal del perito valuador, lo que introduce un componente subjetivo difícil de estandarizar [8]. El problema empeora en zonas donde hay pocas ventas o casas similares, ya que el valuador debe hacer ajustes a ojo, lo que suele provocar errores y diferencias importantes entre el valor dictaminado y el precio real de venta[9].

Como segundo lugar, este tipo de errores de valuación tienen consecuencias financieras directas. Ya que según cifras de la Sociedad Hipotecaria Federal citadas por especialistas del sector, las normativas que regulan los servicios de valuación en México se basan en enfoques metodológicos de hace varios años y no incorporan de forma sistemática el volumen de datos disponible hoy en día [8]. Todo esto genera una brecha tecnológica

frente a mercados más maduros. Aunque no hay un censo que indique cuantas inmobiliarias usan análisis de datos, la ausencia de un sistema de valuación masiva basado en machine learning equivalente al desarrollado en Colombia [7] y el que Brasil, reconociera una brecha frente a Estados Unidos en la adopción de estas herramientas, demuestra el rezago metodológico y técnico que se tiene en el país.

Finalmente, la falta de herramientas para decidir con confianza da mucho que desear para los desarrolladores que necesitan fijar precios de salida competitivos, fondos de inversión inmobiliaria (FIBRAs) que requieren valuar portafolios completos de forma consistente, y compradores individuales que buscan verificar si el precio ofertado corresponde a las condiciones reales del mercado. Por ello, este estudio se justifica al abordar directamente la dispersión de la información mediante técnicas de web scraping y limpieza profunda, mitigando los sesgos y la incertidumbre inherentes a los datos crudos.

Problema

El mercado inmobiliario en México sufre de una falta de claridad visible: propiedades muy similares pueden tener precios completamente diferentes. Esto pasa porque no hay transparencia en cómo se calculan esos montos, un problema que empeora en zonas donde se venden pocas propiedades y no hay información confiable para comparar [8].

Al no existir un sistema claro, los desarrolladores, los fondos de inversión y los compradores individuales terminan tomando decisiones clave basados en criterios subjetivos: la experiencia u opinión personal del perito, un número muy limitado de propiedades para comparar y la simple intuición de cómo se mueve el mercado, en lugar de estimaciones sustentadas en datos [9]. Esto incrementa el riesgo financiero de dichas decisiones, ya sea por sobrevaluación, que prolonga los tiempos de comercialización, o por subvaluación, que representa una pérdida directa de capital.

Este desajuste entre el valor asignado y la realidad operativa quedó en evidencia tras la volatilidad post-pandemia. Durante 2024, el Índice de Fibras (los fondos de inversión inmobiliaria) sufrió una caída anual del 15.5 %, para luego recuperar un 14 % en el primer cuatrimestre de 2025 [10]. Analistas financieros atribuyeron este ajuste al hecho de que las valuaciones de los edificios se había desconectado de la realidad de sus operaciones. Este escenario demuestra que las estrategias de precios estáticos fallan ante las fluctuaciones del entorno, planteando la necesidad urgente de modelos predictivos capaces de actualizarse y adaptarse al mercado en tiempo real.

Objetivos

Objetivo general:

Desarrollar un sistema de apoyo a la toma de decisiones en el sector inmobiliario para la toma de deci-

siones, identificando clústeres de valor y optimizando los precios, mediante técnicas de ciencia de datos, con el fin de llegar a una meta de rentabilidad definida por el mismo proyecto.

Objetivos específicos:

1. Identificar y segmentar zonas conforme a su tipología inmobiliaria mediante técnicas de clustering, a partir de variables físicas y de mercado.
2. Construir un modelo predictivo de precios que estime el valor esperado de las unidades inmobiliarias dentro de cada segmento identificado, considerando sus características y condiciones de mercado.
3. Diseñar un modelo de optimización de precios que, a partir de las estimaciones obtenidas, incorpore restricciones financieras del proyecto y una meta de rentabilidad para generar recomendaciones de precios.

Marco Teórico


Estado del Arte

Cuadro 1: Matriz de antecedentes y trabajos relacionados.

Fecha	Título del Trabajo	Ventajas	Desventajas	Diferencias
2017	Sistema de recomendación de propiedades usando KNN [11]	Utiliza KNN para medir similitud entre propiedades mediante distancia euclidiana, considerando características físicas y ubicación.	Se enfoca en recomendación y filtrado, sin incorporar variables financieras ni modelos predictivos de precios.	No integra modelos de predicción ni optimización, se limita a recomendar encontrar propiedades similares.
2020	Sistema de predicción de precios-venta de inmuebles en el sector inmobiliario de la República de Chile con machine learning. [12]	Compara múltiples modelos de regresión para mejorar la precisión en la predicción de precios.	No segmenta zonas geográficas ni incorpora restricciones financieras del proyecto.	Se limita a la predicción; no segmenta conforme a ubicación ni utiliza una meta de rentabilidad para generar recomendación de precio.
2023	El Big Data en el Sector Inmobiliario. [13]	Integra técnicas de web scraping para obtención de datos y menciona el uso de algoritmos de análisis y predicción.	Aplicación general y poco detallada de los modelos; no hay integración clara entre segmentación y predicción.	El clustering y el modelo predictivo de precios, se usan como análisis distintos.
2024	Estrategias Basadas en Datos para la inversión Inmobiliaria en Airbnb. [14]	Emplea modelos predictivos como árboles de decisión y redes neuronales para estimar demanda y utilidad.	Se centra en predicción de demanda, sin segmentación explícita mediante clustering ni optimización financiera formal.	Se identifican y destacan las zonas más relevantes, a partir de análisis de importancia de variables y de modelos predictivos, no mediante técnicas de segmentación o clustering.
2026	PhiQus Data Science. Empresa consultora que genera soluciones a las empresas mediante el uso de herramientas basadas en Ciencia de Datos e Inteligencia Artificial. [15]	Aplicación real de ciencia de datos para optimización de procesos y toma de decisiones.	Es una página web, no detalla metodología ni modelos utilizados; acceso restringido y enfoque comercial.	Implementa parte del objetivo al que se quiere llegar, solo que se llega a un análisis más profundo.

Metodología

El siguiente diagrama presenta en detalle el desarrollo metodológico que se siguió para el desarrollo del DSS:



Recopilación de Datos

Debido a que en México no existe una base pública oficial que muestre los precios de transacción inmobiliaria y características de inmuebles, se recurrió a la investigación de fuentes de datos alternas. Se recolectaron precios de inmuebles y características mediante técnicas de *web scraping* sobre publicaciones de venta de inmuebles. Para cada propiedad se recopiló información referente al precio de venta, dimensiones del inmueble, número de habitaciones, baños, estacionamientos, pisos, tipo de inmueble y ubicación geográfica (estado, municipio y colonia), conformando un conjunto de datos representativo de la oferta inmobiliaria nacional. Los datos se obtuvieron con fines de investigación y no se redistribuyen ni se usan para negocio.

El proceso de recolección de datos inició a principios del año 2026, con el objetivo de capturar una muestra robusta a nivel nacional. La extracción abarcó los 32 estados del país a nivel colonia por cada entidad federativa. Esta aproximación brindó una perspectiva general del comportamiento del mercado a nivel nacional, sin embargo se decidió focalizarlo a la Zona Metropolitana de Guadalajara Jalisco, permitiendo un estudio más profundo y una segmentación detallada a nivel local.

PONER UNA TABLITA MUESTRA DE COMO QUEDO LA BASE DE DATOS CONFORMADA

Análisis de la Información

Una vez obtenida la información, se realizó una etapa de limpieza y preparación de datos. Inicialmente se eliminaron registros duplicados utilizando el enlace de publicación como identificador. Después, los inmuebles publicados en dólares fueron convertidos a pesos mexicanos utilizando el tipo de cambio correspondiente al periodo de recopilación. Asimismo, se eliminaron variables que no aportaban información al proceso de segmentación, tales como enlaces, fechas de consulta y variables auxiliares utilizadas únicamente durante la recolección de datos.

Luego se desarrolló un análisis exploratorio de datos para comprender el comportamiento de las variables. Se analizó la cobertura geográfica de la información, la distribución de los inmuebles por estado y municipio, así como la composición por tipo de propiedad. De igual manera se estudiaron las distribuciones de las variables numéricas mediante histogramas y estadísticas descriptivas, identificando una marcada asimetría positiva principalmente en el precio y las dimensiones, comportamiento esperado debido a la alta heterogeneidad existente en el mercado inmobiliario.

MOSTRAR TABLAS CON TOP 10 ESTADOS INMUEBLES Y GRAFICAS Y DISTRIBUCION

También se evaluó la correlación entre las variables numéricas mediante una matriz de correlación, observándose ausencia de multicolinealidad severa. Debido a ello se decidió conservar todas las variables originales sin aplicar técnicas de reducción de dimensionalidad para el entrenamiento del modelo, preservando así la interpretabilidad de cada característica.

MOSTRAR MATRIZ DE CORRELACION

Con el propósito de detectar observaciones atípicas se utilizaron dos enfoques complementarios: el Modified Z-Score para evaluar valores extremos de forma univariada y la distancia de Mahalanobis para detectar anomalías considerando simultáneamente todas las variables numéricas. Aunque se identificaron diversos registros atípicos, estos no fueron eliminados debido a que representan segmentos reales del mercado inmobiliario, tales como propiedades de lujo o inmuebles con características poco comunes. Su eliminación habría reducido la capacidad del modelo para representar adecuadamente la diversidad existente en la oferta.

GRAFICO DE VALORES ATIPICOS

Ingeniería de Características

Posteriormente se incorporaron variables de contexto económico con el fin de representar el comportamiento del mercado local. Para ello se construyó la variable "Zona" mediante la combinación del estado y municipio de cada inmueble. A partir de esta agrupación se calcularon medianas de precio siguiendo una jerarquía geográfica (zona, municipio y estado), utilizando umbrales mínimos de observaciones para garantizar estimaciones robustas. Cuando una zona no contaba con suficientes registros, el valor era sustituido por la mediana del municipio y, en última instancia, por la mediana estatal. De esta forma se obtuvo una variable denominada Precio de mercado por zona, la cual resume el nivel de precios característico del entorno donde se ubica cada propiedad.

Enseguida se evaluaron diferentes transformaciones estadísticas para reducir la asimetría de las variables continuas, comparando transformaciones logarítmicas, raíz cuadrada, Box-Cox y Yeo-Johnson. Con base en la reducción del coeficiente de sesgo y en la facilidad de interpretación de los resultados, únicamente se aplicó la transformación logarítmica al precio y a las dimensiones del inmueble, ya que fueron las únicas variables que presentaron un sesgo considerable.

Segmentación

La primera etapa del sistema consistió en la segmentación del mercado inmobiliario mexicano *con el objetivo de identificar grupos homogéneos de inmuebles que compartieran características similares tanto desde el punto de vista físico como desde el contexto económico y geográfico en el que se encuentran ubicados. Esta segmentación permite representar la estructura del mercado para posteriormente utilizar dicha información como variable explicativa dentro del modelo de predicción del precio.

Antes de realizar el proceso de agrupamiento, el conjunto de datos se dividió en subconjuntos de entrenamiento y prueba 80 % y 20 %, respectivamente. Esta separación permitió calcular todas las variables derivadas exclusivamente con información del conjunto de entrenamiento, evitando fuga de información (data leakage) y permitiendo evaluar posteriormente la estabilidad de la segmentación sobre datos no utilizados durante el entrenamiento.

Debido a las diferencias estructurales entre casas y departamentos, la segmentación se realizó de forma independiente para cada tipo de inmueble. Esta decisión permitió identificar patrones específicos de cada mercado, evitando que las diferencias entre ambos tipos de propiedades dominaran el proceso de agrupamiento.

Como variables de entrada para el algoritmo de clustering se utilizaron tanto características físicas del inmueble (dimensiones, número de habitaciones, baños, estacionamientos y pisos) como la variable económica correspondiente al precio de mercado de la zona. Esta combinación permitió que los grupos reflejaran

simultáneamente atributos constructivos y el contexto económico en el que se localiza cada propiedad.

Para la construcción de los clusters se empleó el algoritmo K-Means. Inicialmente se evaluaron diferentes valores del número de grupos mediante indicadores internos de validación, incluyendo la inercia, el coeficiente de Silhouette y el índice de Calinski-Harabasz. Aunque algunas métricas sugerían soluciones con pocos grupos, éstas producían segmentos excesivamente generales y con escasa utilidad práctica para describir la diversidad del mercado inmobiliario.

Por ello, además de las métricas cuantitativas, se incorporó un criterio de interpretabilidad, evaluando el tamaño relativo de cada grupo y las características representativas de los inmuebles contenidos en ellos.

Una vez obtenidos los modelos definitivos, los clusters fueron analizados mediante estadísticas descriptivas de sus variables originales, permitiendo caracterizar cada segmento según su nivel de precio, dimensiones y atributos físicos predominantes. Asimismo, se utilizaron técnicas de reducción de dimensionalidad, específicamente PCA y t-SNE, únicamente como herramientas de visualización para explorar gráficamente la separación entre los grupos, sin intervenir en el proceso de entrenamiento del modelo.

Finalmente, la estabilidad de la segmentación fue evaluada comparando el coeficiente de Silhouette obtenido tanto en el conjunto de entrenamiento como en el conjunto de prueba. Esta validación permitió verificar que los patrones identificados por el algoritmo se mantienen sobre datos no utilizados durante el entrenamiento, proporcionando evidencia de la robustez de la segmentación.

Como resultado de esta metodología se obtuvo una variable categórica que representa distintos segmentos del mercado inmobiliario mexicano. Esta información constituye la salida de la primera etapa del Sistema de Soporte a la Decisión y será utilizada posteriormente como una variable explicativa dentro del modelo de predicción del precio de los inmuebles, permitiendo incorporar el comportamiento estructural del mercado al proceso de estimación.

Modelo Predictivo

Una vez definidos los segmentos, se construirá un modelo supervisado para estimar el valor esperado de las unidades inmobiliarias dentro de cada grupo identificado.

Modelo Optimización Convexa

Resultados

Conclusión

Trabajo Futuro

Referencias

- [1] Instituto Nacional de Estadística y Geografía (INEGI). (2024) Vivienda. [Online]. Available: <https://www.inegi.org.mx/temas/viviendasat/>
- [2] SEDATU, “Salen del rezago habitacional 5.8 millones de personas en México: Sedatu,” <https://www.gob.mx/sedatu/prensa/salen-del-rezago-habitacional-5-8-millones-de-personas-en-mexico-sedatu>, ago 2025, consultado en línea.
- [3] CONAVI, “Estimación del déficit cualitativo de vivienda en México 2024,” Comisión Nacional de Vivienda, Reporte técnico, 2025. [Online]. Available: https://siesco.conavi.gob.mx/doc/analisis/2025/Estimaci%C3%B3n_del_d%C3%A9ficit_cualitativo_de_vivienda_en_M%C3%A9xico_2024.pdf
- [4] Banco de México, “Tasa de interés anual del crédito a la vivienda,” <https://www.banxico.org.mx/TablasWeb/informes-trimestrales/abril-junio-2025/E8946059-9706-4F16-8158-5AE2955B1DB9.html>, 2025, consultado en línea.
- [5] Real Estate Market & Lifestyle, “Mercado industrial de Monterrey se estabiliza tras boom del nearshoring,” <https://realestatemarket.com.mx/noticias/mercado-inmobiliario/50613-mercado-industrial-de-monterrey-se-estabiliza-tras-boom-del-nearshoring>, may 2026, datos con base en reporte MarketView de CBRE.
- [6] AMPIP, “Parques industriales en México 2026,” <https://revistafortuna.com.mx/2026/05/15/parques-industriales-en-mexico-aceleran-expansion-inversion-crecera-50-en-2026-ampip/>, may 2026, citado en Revista Fortuna.
- [7] Universidad de los Andes, “Implementación de un modelo machine learning para la estimación del valor del metro cuadrado de un inmueble ubicado en Cundinamarca,” Master’s thesis, Universidad de los Andes, n.d. [Online]. Available: <https://repositorio.uniandes.edu.co/entities/publication/666a362e-de26-459f-878d-0ed510337616>
- [8] C. Salas Tafoya, “La valuación inmobiliaria tradicional: un modelo para repensar,” *PAAKAT: Revista de Tecnología y Sociedad*, n.d. [Online]. Available: <http://www.udgvirtual.udg.mx/paakat/index.php/paakat/article/view/220/324>
- [9] UNAM, “Uso del enfoque de mercado y el ajuste de valuación inmobiliaria,” Master’s thesis, Universidad Nacional Autónoma de México, 2013. [Online]. Available: <https://tesiunamdocumentos.dgb.unam.mx/ptd2013/Presenciales/0702043/0702043.pdf>
- [10] Real Estate Market & Lifestyle, “Las fibras inmobiliarias retoman fuerza en 2025,” <https://www.realestatemarket.com.mx/mercado-inmobiliario/48186-las-fibras-inmobiliarias-retoman-fuerza-en-2025>, 2025, con base en análisis de Monex e Intercam.

- [11] J. I. González Cárdenas and A. González Meléndrez, “Sistema de recomendación de propiedades usando KNN,” Proyecto de Aplicación Profesional, Instituto Tecnológico y de Estudios Superiores de Occidente (ITESO), Tlaquepaque, Jal., México, 2017. [Online]. Available: <https://rei.iteso.mx/items/1a95ed7d-ab41-4fa9-9c84-ded3268cb035>
- [12] M. S. Bozanic Leal, “Sistema de predicción de precios-venta de inmuebles en el mercado del sector inmobiliario de la Región Metropolitana de la República de Chile con el uso de algoritmos de machine learning,” Memoria de Título, Universidad de Chile, Santiago, Chile, 2020. [Online]. Available: <https://repositorio.uchile.cl/handle/2250/176909>
- [13] J. L. Moreno Rodríguez, “El Big Data en el Sector Inmobiliario,” Trabajo de fin de grado, Universidad Pontificia Comillas, Madrid, España, 2023. [Online]. Available: <https://repositorio.comillas.edu/jspui/retrieve/624301/TFG-%20Moreno%20Rodriguez%2C%20Jose%20Luis.pdf>
- [14] J. P. Acevedo Robles, “Estrategias Basadas en Datos para la inversión Inmobiliaria en la Era de Airbnb,” Tesis de Maestría, Instituto Tecnológico y de Estudios Superiores de Occidente (ITESO), Tlaquepaque, Jal., México, 2024. [Online]. Available: <https://rei.iteso.mx/items/101f9202-9072-4aa1-b1b5-7be1b72811a5>
- [15] Phiquis Software. (2026) Phiquis DataScience. [Online]. Available: <https://phiquis.com/>